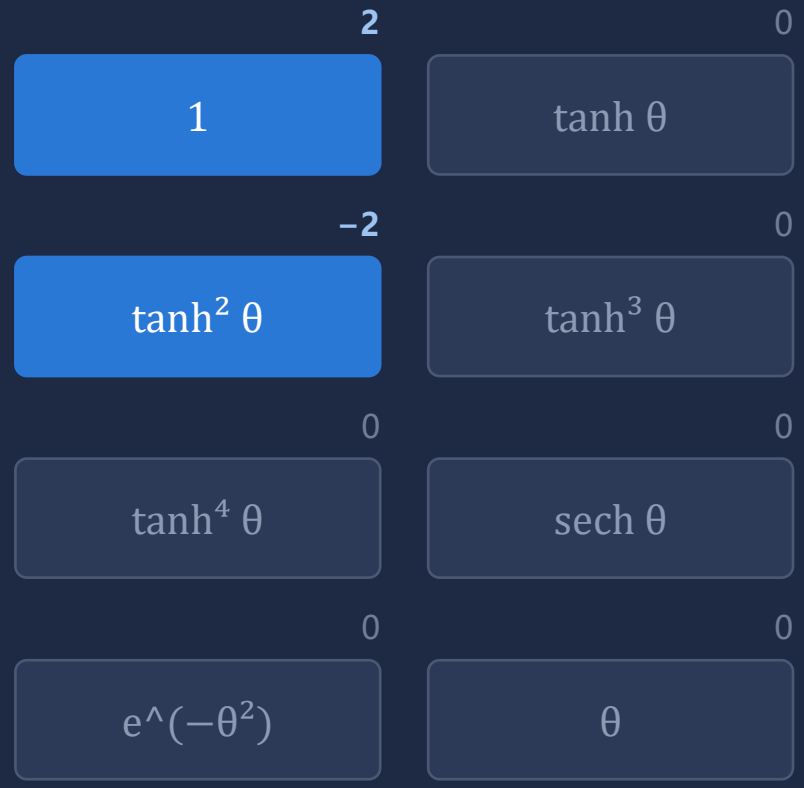
用 L1 稀疏库求 PDE 的解析解与控制方程

算法迭代 · 核心公式 · 噪声分析 · 与 SGA-PDE 对比

进展汇报 · 2026-10-30



$$u = 2 - 2\tanh^2\theta = 2\mathrm{sech}^2(x - 4t)$$

汇报内容

01

背景

老师的思路、两个方向、相关工作

02

算法与迭代

五次迭代：每次遇到什么问题、怎么改、核心公式

03

实验结果

无噪声、反例门槛、加高斯噪声的误差分析

04

对比

自写遗传算法、SGA-PDE、各方法优劣

05

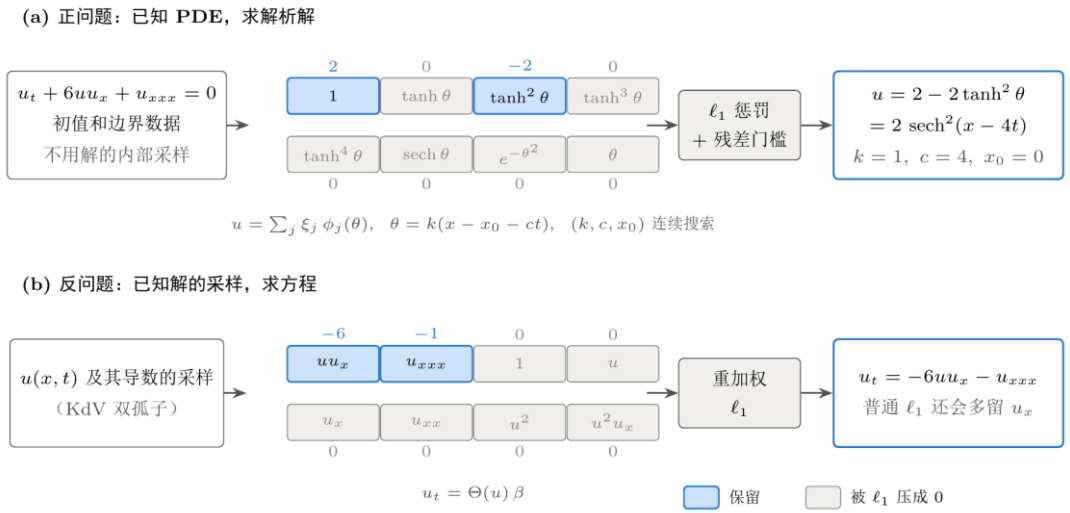
总结

结论、局限与下一步

思路：把“猜解 / 猜方程”变成“从候选库里选项”

先列很多候选项，每项配一个未知系数，用 L1 把绝大多数系数压成 0，剩下的几项就是答案。

方向	已知	要找	候选库里放什么	例子
正问题：求解析解	方程 + 初值 / 边界数据	解 u(x,t) 的表达式	函数项 1、tanh θ、$\tanh^2\theta$、sech θ …	KdV → $2 - 2\tanh^2\theta$
反问题：求方程	解的数据 u(x,t)	控制方程 u_t = …	导数项 u、u_x、u_{xx}、uu_x、u^3 …	KdV → $u_t = -6uu_x - u_{xxx}$



怎么算“真的找到了”

- 选出的项 = 真项，一项不多一项不少
- 代回方程，残差降到 10^{-8} 以下（无噪声）
- 多个随机种子都成立

相关工作：三类方法，我们属于“固定候选库”

固定候选库

SINDy、PDE-FIND、本文

先列好候选项，再做稀疏回归选项

快、可解释；真项必须在库里

可扩展候选库

DLGA-PDE（Xu 等 2020）

遗传算法往库里加新项，再稀疏回归

库能长大；搜索变慢

开放形式

SGA-PDE（Chen 等，PRR 2022）

遗传算法直接进化符号树，不预设库

能发现库外项；慢、结果随机

我们的不同：同一套工具同时做正问题（已知方程求闭式解，文献少）和反问题；用精确 L1 路径解释并修掉了普通 L1 “多留 u_x”的现象。

算法演进：五次迭代，每次解决一个具体问题

v0

离散库 + 普通 L1

问题：反问题总多留 u_x

精确 LARS 复现，排除“没收敛”

v1

加权 L1（IRL1）

问题：u_x 去不掉

按上一轮系数加权，两轮去掉

v2

通用库 + 连续波参数

问题：旧库里本来就放了答案

tanh 展开库，(k, c, x_0) 连续搜

v3

多起点 LM + 延长迭代

问题：Burgers 种子只过 3/5

最好起点再迭代 3000 步，5/5

v4

弱形式 + 统一判据

问题：加噪声后求导误差 45%

积分代替求导；MSTLS 判据选项

不变的约束：哪几项留下只由 L1 决定；支撑阈值 10^{-5} 不放宽；重拟合只读系数、不增删项。

核心公式①：L1 稀疏回归（Lasso）

$$\min_{\xi} \tfrac{1}{2}\|A\xi - b\|_2^2 + \lambda \sum_j |\xi_j|$$

A、b、ξ 是什么

- A 的每一列 = 一个候选项在所有网格点上的值
- b = 要拟合的量（反问题里是 u_t）
- ξ = 每个候选项的系数，绝大多数应为 0

λ 的作用：罚款单价

- λ 大：每留一项都要多付罚款 → 留下的项少
- λ 小：罚款便宜 → 为了误差小会多用项
- λ 从大往小扫，项逐个“进场” = λ 路径

为什么系数能精确为 0

- |ξ| 在 0 处有尖角，最优点会卡在 0 上
- 平方罚（岭回归）没有尖角，只会变小
- 所以 L1 能“选项”，岭回归不能

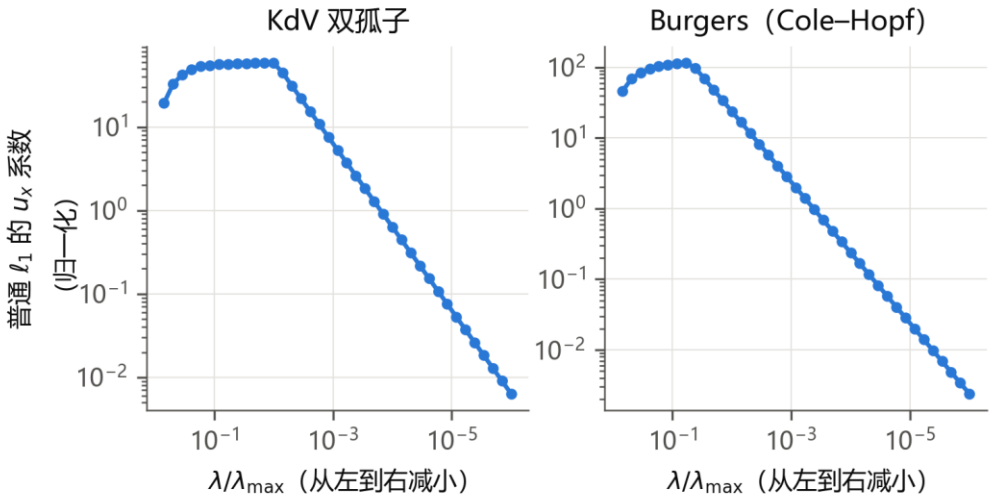
正问题里残差 r(ξ) 非线性，用 Gauss–Newton 线性化，每步解一个上面形式的 L1 子问题

核心公式②：LARS 精确走完整条 λ 路径

$$|A_j^T(b - A\xi)| \le \lambda，且\ \xi_j \neq 0\ 时取等号$$

最优解的条件（KKT）：在场的项与残差的相关度都等于 λ，场外的都不超过 λ。

1. λ 很大时系数全为 0；与残差最相关的列第一个进场
2. 在场系数沿“等角方向”一起变：各列与残差的相关度同速下降
3. 场外某列追平 → 进场；在场系数碰到 0 → 退场
4. 在这个转折点重算方向，直到 λ 降到下限



为什么用它

- 路径是分段直线，只有十几个转折点，算出来就是精确解（KKT 误差 < 5×10^{-9}）
- 排除“求解器没收敛”的解释
- 每段的非零项就是一个候选组合（约 15 个）

迭代一 → 问题：普通 L1 总多留一个 u_x

$$\| A_S^{cT} A_S (A_S^T A_S)^{-1} \operatorname{sign}(\xi_S) \|_\infty < 1$$

不可表示条件：S = 真项，S^c = 错项。错列不能太像“真项的组合”，否则 L1 一定会选它。

通俗地说

- 行波数据里，u_x 这一列和真项（如 uu_x）的组合长得非常像
- L1 发现：用 u_x 顶替一部分真项，罚款更便宜、误差差不多
- 于是不管 λ 取多小，u_x 都会被留下；这是 L1 本身的局限，不是程序错误
- u_x 系数与 λ 成正比地变小，所以旧的 10^{-8} 残差门槛整条路径都到不了

u_x 那一列的指标（> 1 就会被选）

2.77	KdV 双孤子
1.39	Burgers，Cole–Hopf
1.52	Burgers，两行波

其余错列的指标都 < 1，正好解释了为什么只多留 u_x 一项

迭代二：加权 L1（IRL1），两轮去掉 u_x

$$\min_{\xi} \tfrac{1}{2}\|A\xi - b\|^2 + \lambda \Sigma_j w_j|\xi_j|, \quad w_j^{(t+1)} = 1 / (|\xi_j^{(t)}| + \varepsilon)$$

1 第 0 轮：普通 L1（$\lambda = 10^{-3}\,\lambda_max$）

KdV 选 $\{uu_x, u_{xxx}, u_x, u_{xx}\}$；Burgers 选 $\{uu_x, u_{xx}, u_x\}$

2 改权重

系数大的项罚得轻，系数小的项（u_x）罚得重

3 第 1 轮起只剩真项，支撑不再变化就停

KdV：uu_x (−6)、u_{xxx} (−1)；Burgers：uu_x (−1)、u_{xx} (0.1)

第 0 轮 λ 比例的敏感性（每格 4 个 ε）

λ/λ_max	KdV	Burgers CH	两行波
10^{-1}	失败	失败	失败
10^{-2}	失败	通过	通过
10^{-3}	通过	通过	通过
10^{-4}	通过	通过	通过
10^{-5}	通过	通过	通过

比例太大时第 0 轮漏掉真项，重加权会锁死错的支撑；论文固定 10^{-3}

迭代三：正问题改用通用库，库里不直接放答案

$$u(x,t) \approx \Sigma_j \, \xi_j \, f_j(\theta), \quad \theta = k\,(x - ct - x_0)$$

旧库：针对真解设计

$2\mathrm{sech}^2(x-4t)$	$c = 1$ 孤子
$c = 2$ 孤子	$c = 9$ 孤子

- 库里直接有真解那一列
- 波速预先离散成几列
- L1 只是在几列里挑一列

新库：三个方程共用

1	$\tanh\theta$	$\tanh^2\theta$	$\tanh^3\theta$
$\tanh^4\theta$	$\mathrm{sech}\,\theta$	$e^{(-\theta^2)}$	θ

- 前五项：tanh 展开法常用项；后三项：干扰项
- k、c、x_0 不告诉程序，连续搜索
- 没有任何一列等于真解，要几列拼出来

$$\min \ \tfrac{1}{2}\|r(\xi, k, c, x_0)\|^2 + \lambda \Sigma_j \, w_j|\xi_j|, \quad r = [\text{PDE 配点残差；边界误差；初值误差}]$$

核心公式③：多起点 Levenberg–Marquardt 找波参数

$$(J^{T}J + \mu \cdot \mathrm{diag}(J^{T}J))\,\delta = -J^{T}\,r, \quad z \leftarrow z + \delta$$

$z = (\xi, k, c, x_0)$，J = 残差对 z 的雅可比

通俗地说：在山谷里找最低点

- μ 小 ≈ 高斯–牛顿：按地形曲率直接“跳”到估计的最低点，近处很快
- μ 大 ≈ 梯度下降：顺最陡方向小步走，稳但慢
- 这一步误差变小就减小 μ（更敢跳），变大就增大 μ（退回小步）

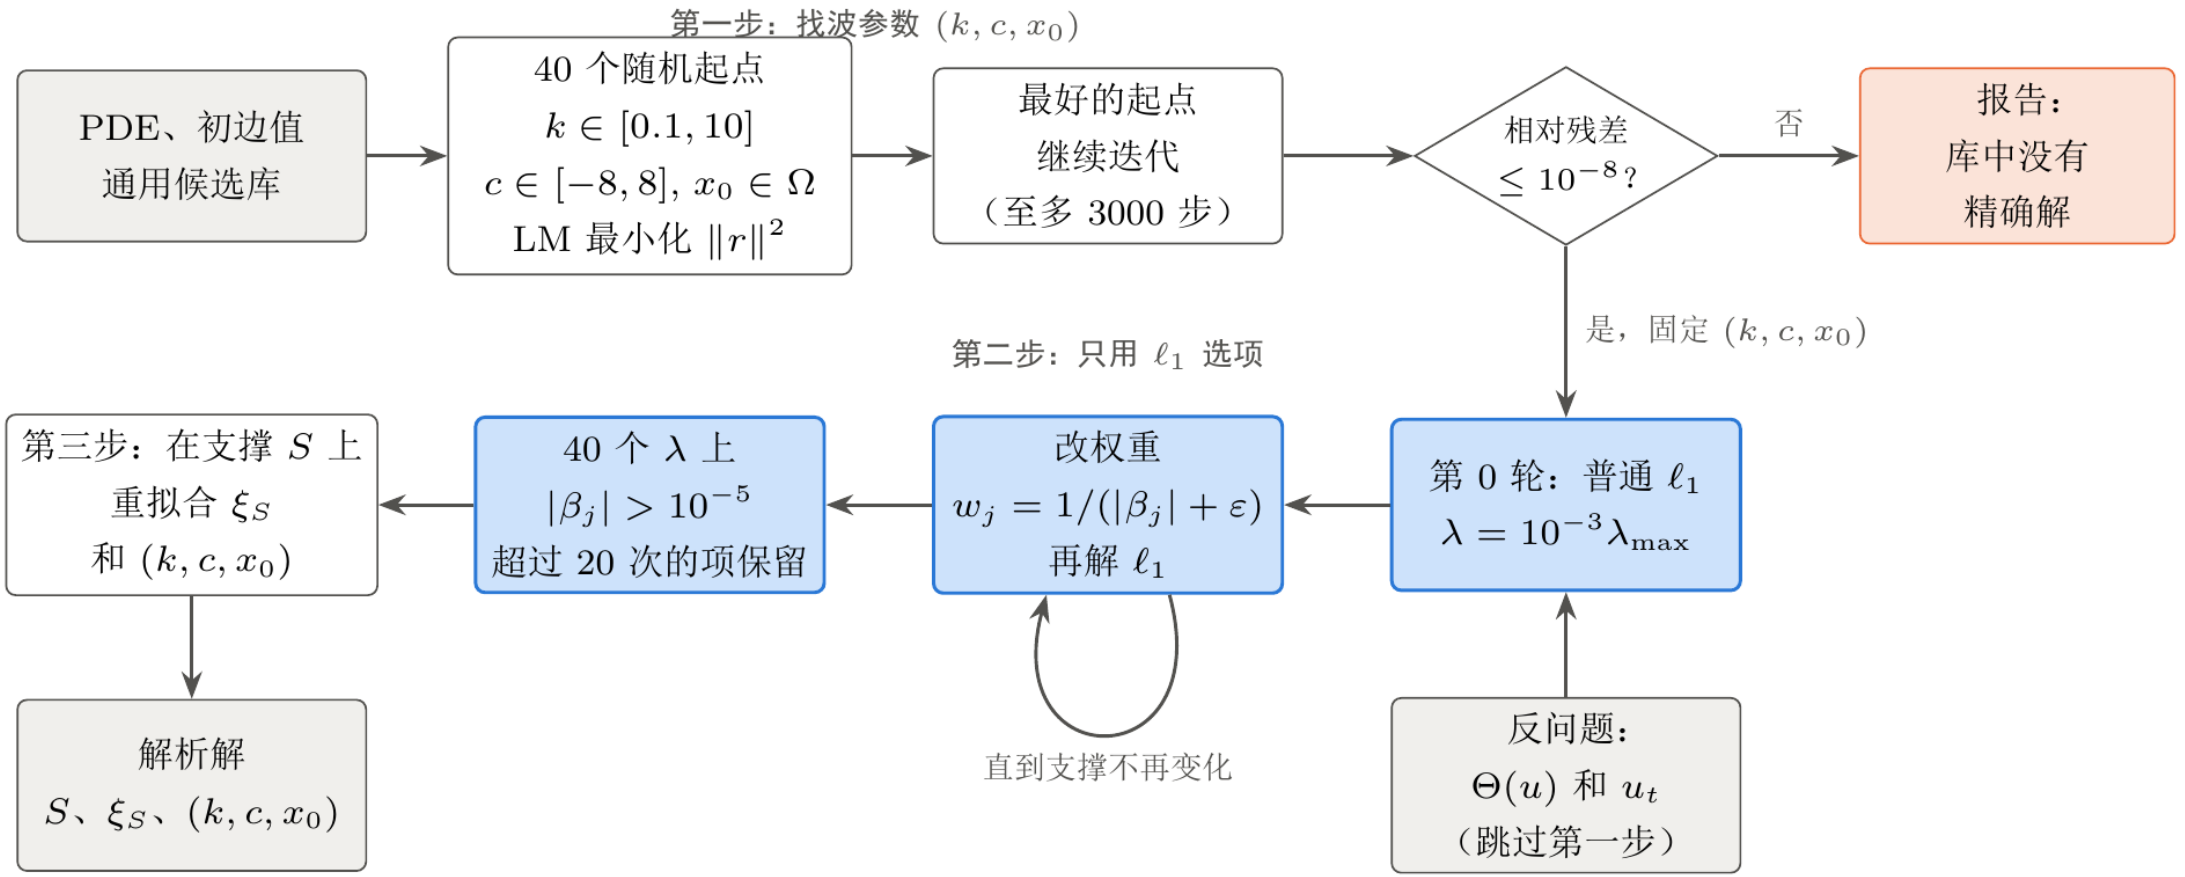
弱点：只找附近的低谷 → 从 40 个随机起点各跑一遍取最好；v3 再对最好的起点继续迭代最多 3000 步

Burgers：延长迭代前后的最好残差

种子	300 步	延长后
0	1.4×10^{-10}	1.3×10^{-10}
1	3.4×10^{-9}	3.7×10^{-11}
2	1.3×10^{-10}	1.3×10^{-10}
3	**1.9×10^{-8}**	**4.2×10^{-11}**
4	**2.5×10^{-8}**	**4.3×10^{-11}**

门槛 10^{-8}：种子 3、4 原来过不了，延长后 5/5 通过；其他规则一概不变

正问题完整流程：先过门槛，再让 L1 选项



第一步：全库多起点 LM（不加 L1）；门槛：残差 ≤ 10^{-8} 才算库里拼得出解，否则拒绝；第二步：固定 (k, c, x_0) 走加权 L1 路径定支撑；第三步：只在支撑上重拟合。反问题直接从第二步进入。

迭代四：加噪声后改用弱形式，不对噪声数据求导

$$\int \varphi\, \partial_x{}^k(u^m)\, dx\, dt \;=\; (-1)^k \int (\partial_x{}^k \varphi)\, u^m\, dx\, dt, \qquad \varphi = (1 - s^2)^6$$

问题

直接差分求导会放大噪声：1% 噪声时 u_{xx} 误差已达 45%，BIC 在无噪声时也多选项

做法

拿一个光滑“小鼓包” φ 乘方程两边再积分，分部积分把导数挪到 φ 上；φ 放在很多位置，每个位置是方程组一行

为什么有效

φ 的导数用公式算，没有误差；u 不用求导，只参与积分，正负噪声互相抵消

候选库随之改写成 $\partial_x{}^k(u^m)$（13 列）：只有“某个东西的导数”才能分部积分，所以 uu_x 写成 $\frac{1}{2}(u^2)_x$，KdV 的 $6uu_x$ 写成 $3(u^2)_x$，意思完全一样。

迭代五：统一判据，只比“谁能产生正确的候选组合”

$$L(S) = \|A(w_S - w_LS)\| / \|A\ w_LS\| \ + \ |S| / p$$

第一项：拟合变差了多少

只用组合 S 里的项，比用全部项拟合差了多少。少了真项，这一项会变大。

第二项：用了多少项

S 占库的比例（p = 13）。多了假项，这一项会变大。

为什么统一

L1、加权 L1、STRidge、遗传算法、穷举都用它挑最终组合，差别只在怎么产生候选，比较才公平。

正问题有噪声时，门槛也要跟着改（差异原理，假定噪声大小 σ 已知）：

$$\|r\| / \|数据\| \ \le \ 3 \times \sqrt{2} \cdot \sigma \cdot std(u_ic) / \|数据\|$$

无噪声结果：正、反问题各 5 个，全部选对

方程	正问题：L1 选出的解析解	反问题：L1 选出的方程
热方程	**$e^{(-\pi^2 t)} \sin \pi x$**	**$u_t = u_{xx}$**
波动方程	**$\cos \pi t \sin \pi x$**	**$u_{tt} = u_{xx}$**
粘性 Burgers	**$0.5 - 0.5 \tanh \theta$（通用库）**	**$u_t = -uu_x + 0.1u_{xx}$（加权 L1）**
Chafee–Infante	**$\tanh(x/\sqrt{2})$（通用库）**	—
KdV	**$2 - 2\tanh^2\theta$（通用库）**	**$u_t = -6uu_x - u_{xxx}$（加权 L1）**
平流扩散	—	**$u_t = -0.4u_x + 0.05u_{xx}$**

数据全部是精确解；反问题的热方程、波动方程用两个模态（单模态满足更短的等价方程）

$\leq 10^{-15}$

通用库重拟合后波参数误差

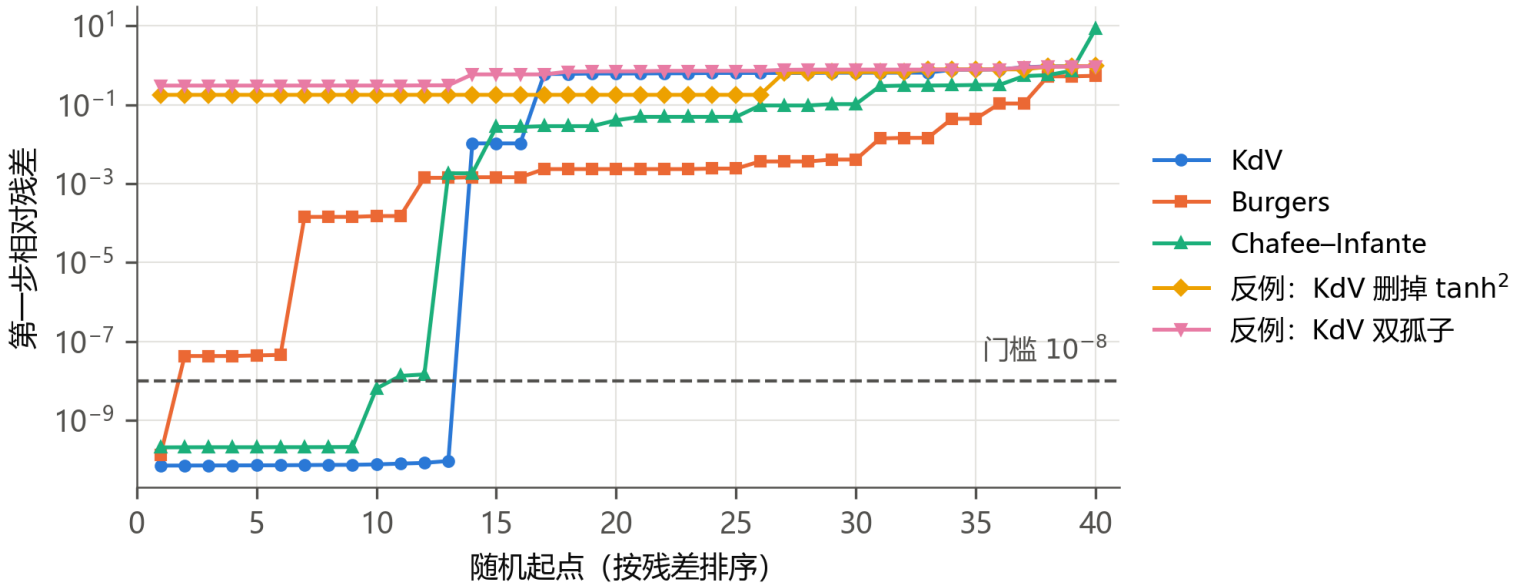
5 / 5

每个通用库正例在 5 个随机种子下都选对

10^{-8}

残差门槛；正例最好起点都 < 2×10^{-10}

库里没有答案时，方法会明确拒绝



每个情形 40 个随机起点的残差（排序）；虚线是门槛 10^{-8}

正例

最好的起点都 < 2×10^{-10}

反例 1：库里删掉 $\tanh^2$

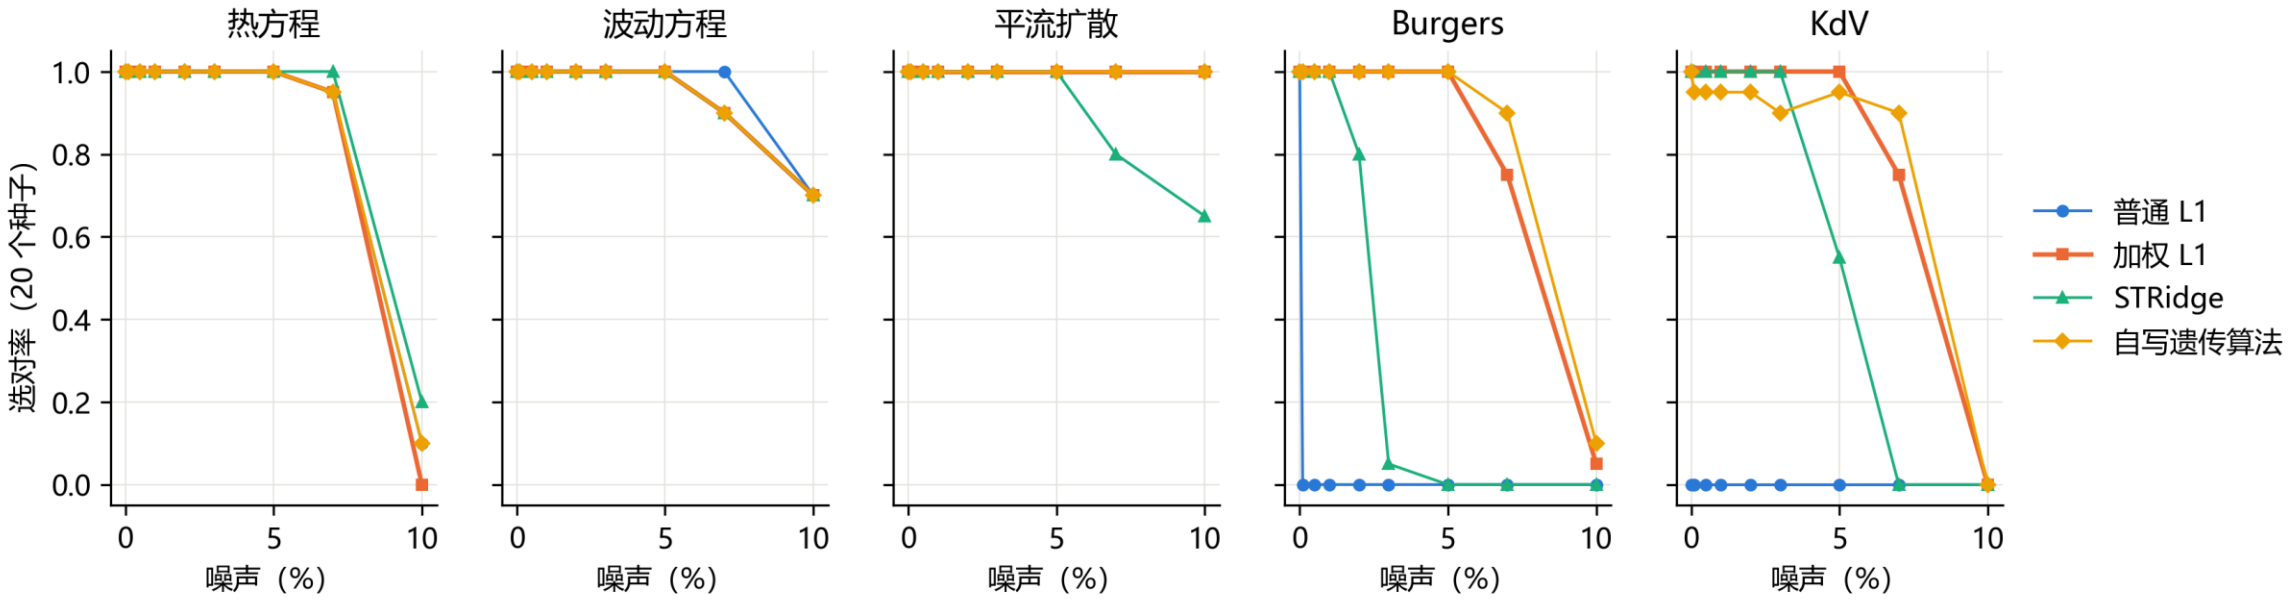
最好残差 0.178，拒绝

反例 2：KdV 双孤子

不是单一行波，残差 0.306，拒绝

正、反例残差相差 7 个数量级

反问题加高斯噪声：加权 L1 到 5% 全部选对



噪声 = σ·std(u)·N(0,1)；5 个方程 × 9 个噪声水平 × 20 个种子；所有方法共用弱形式和同一判据

5 / 5

个方程到 5% 噪声全部选对（加权 L1）

0 / 20

普通 L1 在 KdV 上任何噪声都多留 u_x

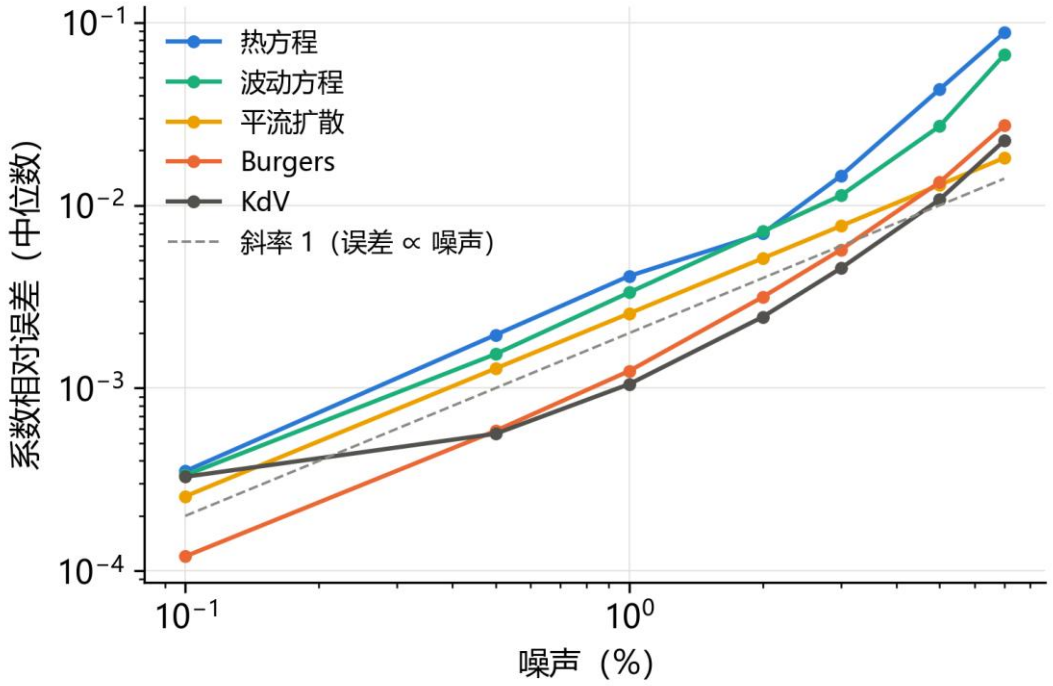
1 ~ 3%

STRidge 在 Burgers 上开始出错的噪声

10%

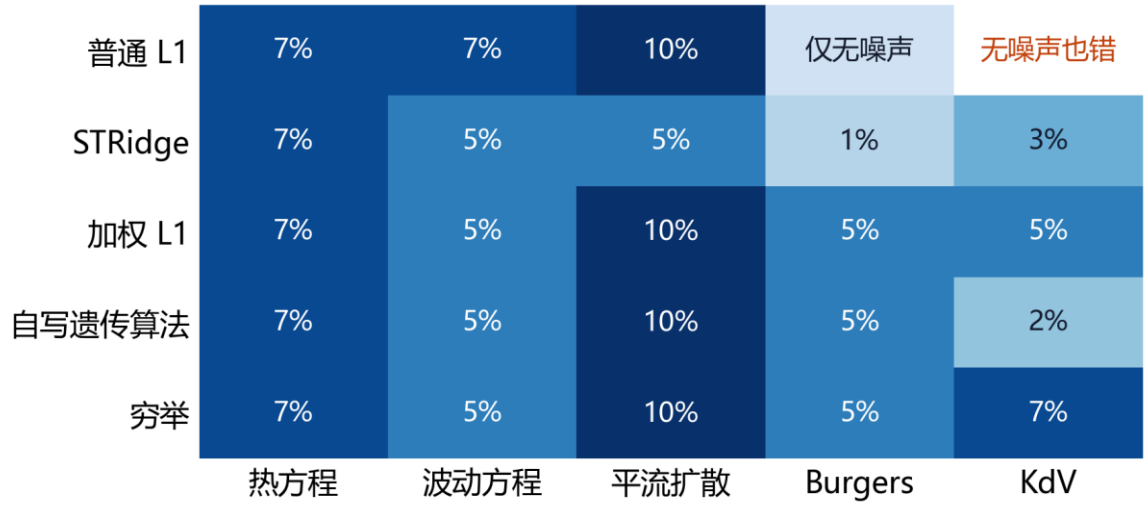
热方程、Burgers、KdV 连穷举都错：数据信息不够

误差分析：系数误差与噪声成正比；各方法能承受的噪声



加权 L1 系数相对误差（中位数）。2～3% 以内贴着斜率 1，之后增长更快；KdV 有约 3×10^{-4} 的积分误差下限

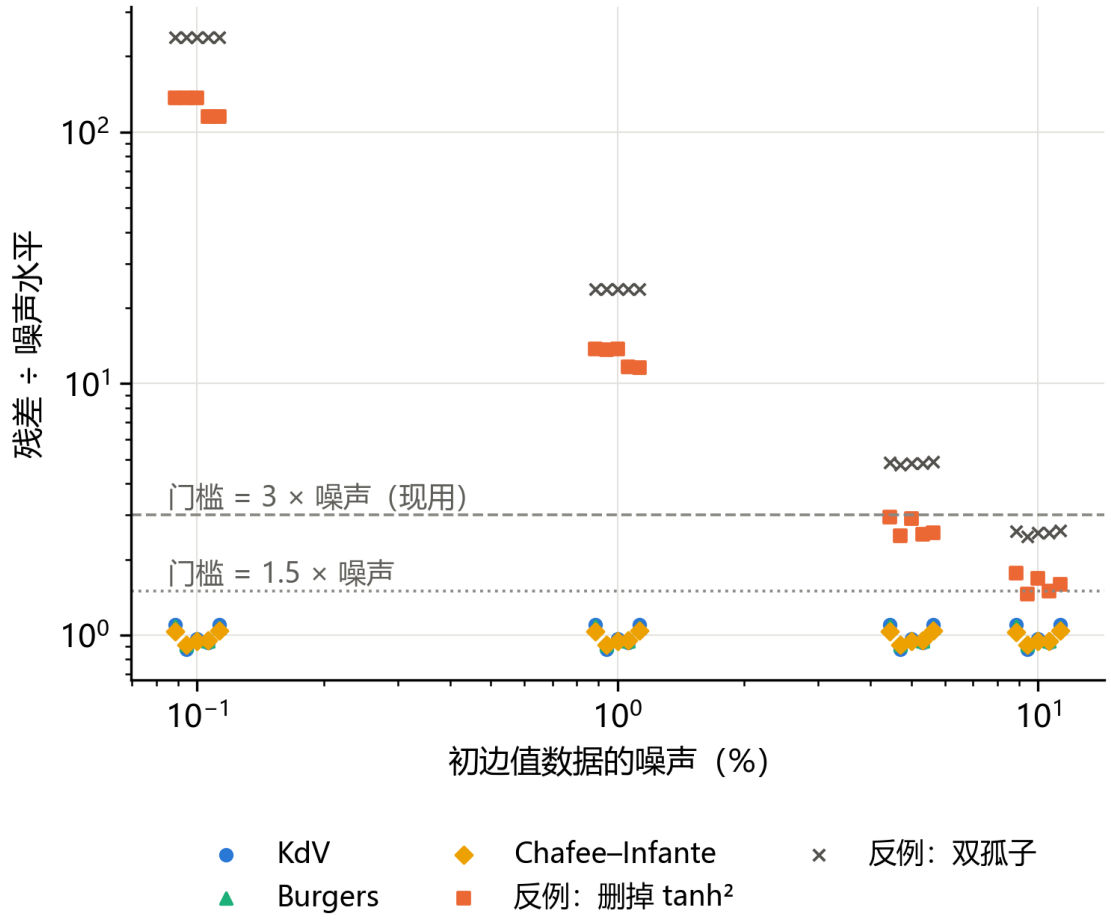
选对率 ≥ 0.95 时能承受的最大噪声



加权 L1 与穷举（判据上界）基本一致；遗传算法在 KdV 上偶尔卡住；普通 L1 和 STRidge 明显更早失败

举例：Burgers 1% 噪声时系数误差 0.12%，5% 时 1.3%

正问题加噪声：真解全部找对，门槛倍数需要收紧



情形	1%	5%	10%
3 个真解	5/5 对	5/5 对	5/5 对
删 $\tanh^2$	拒绝	放过	放过
双孤子	拒绝	拒绝	放过

初边值数据加噪声 0.1%～10%，5 个种子。10% 噪声时 KdV 系数误差 0.5%；系数和波参数误差都与噪声成正比

待定：门槛倍数 3 还是 1.5

真解残差稳定在噪声的 0.88～1.10 倍；改成 1.5 倍后只剩“删 $\tanh^2$”在 10% 时放过 2/5，真解仍全部通过

论文原来的“过半”选项规则在噪声下会失效（Burgers 5% 时 0/5），改用统一判据后全部选对

对比一：自写遗传算法（同一判据，只比搜索方式）

编码：每个个体是一串 0/1，每位对应库里一项，1 = 选



1. **适应度** 判据 L(S)，越小越好
2. **选择** 3 个里挑最好的（锦标赛）
3. **交叉** 两个父代每位随机取一个
4. **变异** 每位以 1/13 概率翻转
5. **精英** 最好的 2 个直接保留

种群 40，跑 60 代

	加权 L1	自写遗传算法
5% 噪声以内	**5 个方程全对**	**KdV 偶尔卡在 $\{u_x\}$**
7% 噪声 Burgers / KdV	**0.75 / 0.75**	**0.90 / 0.90**
扩展库 PDE_divide 1%	**0/3**	**3/3**
每次评估判据次数	**约 15**	约 450
耗时（中位数）	**2.7 ms**	92 ms
结果是否随机	**固定**	随种子变

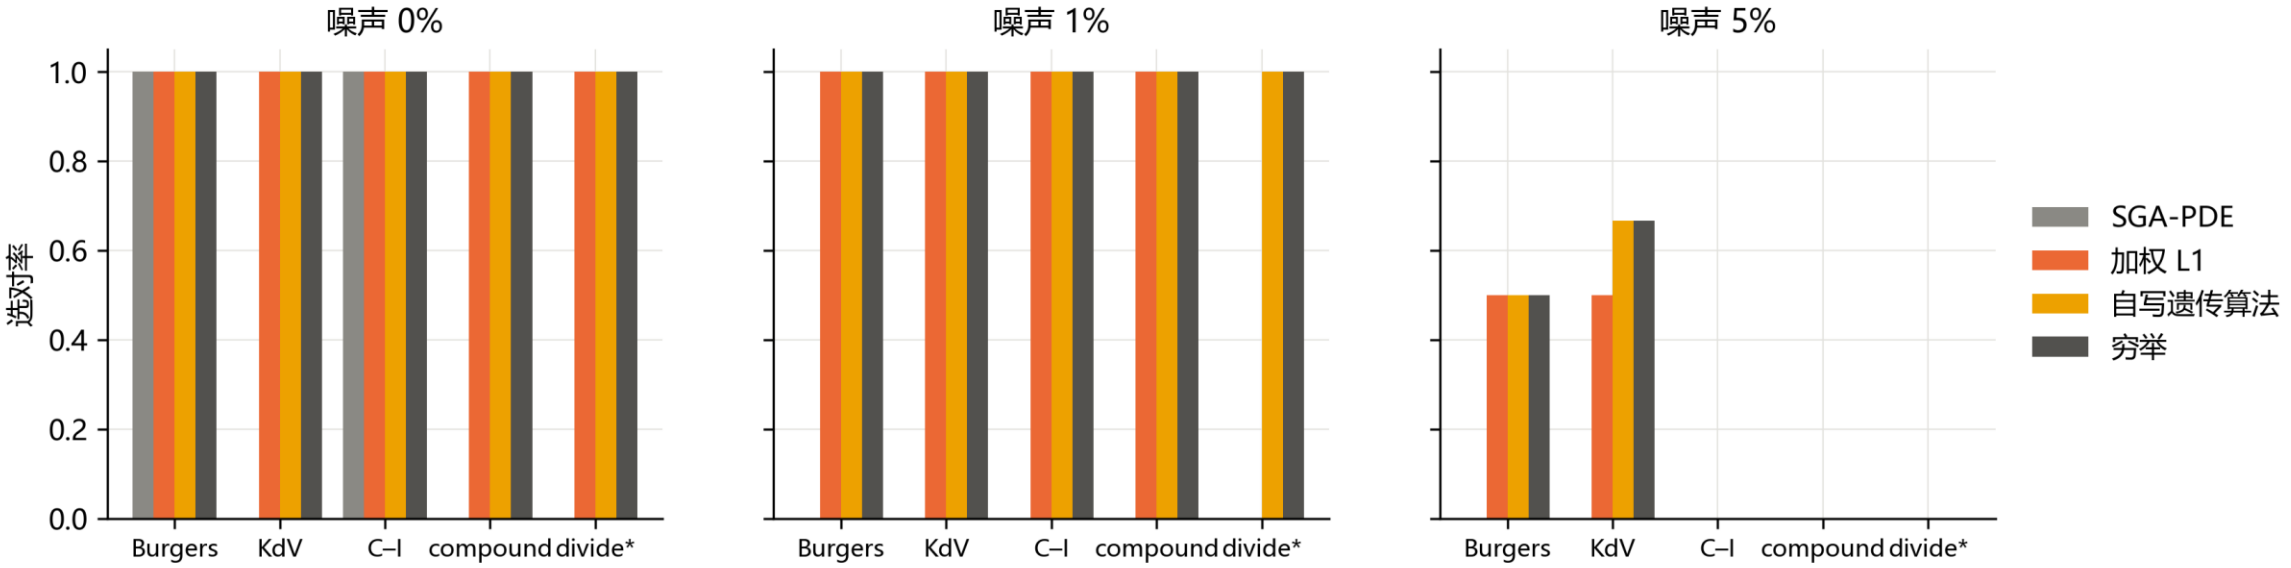
低噪声打平；高噪声或库项很相似时遗传算法更稳，代价是约 30 倍计算量

对比二：SGA-PDE 和我们的方法在做法上的差别

	SGA-PDE（Chen 等，PRR 2022）	本文（加权 L1）
候选项从哪来	遗传算法进化符号树，如 u·(u d x)	预先列好的固定候选库（13 列）
导数怎么算	有限差分直接对数据求导	弱形式：积分代替求导
怎么选项	交叉 + 变异 + 替换，100 代	加权 L1 的 λ 路径（LARS 精确解）
每个候选怎么评分	STRidge 拟合系数，AIC（误差 + 项数罚）	MSTLS 判据 L(S)
能否找到库外项	**能，结构自由**	**不能，真项必须在库里**
计算量 / 随机性	约 30 分钟 / 结果随种子变	约 3 毫秒 / 结果固定

对比设置：同一份带噪声数据同时给两边；SGA-PDE 用论文默认参数（种群 20、深度 4、宽度 5、100 代），每次限时 30 分钟，代码未改

对比二结果：SGA-PDE 论文的 5 个方程，有噪声时它全错



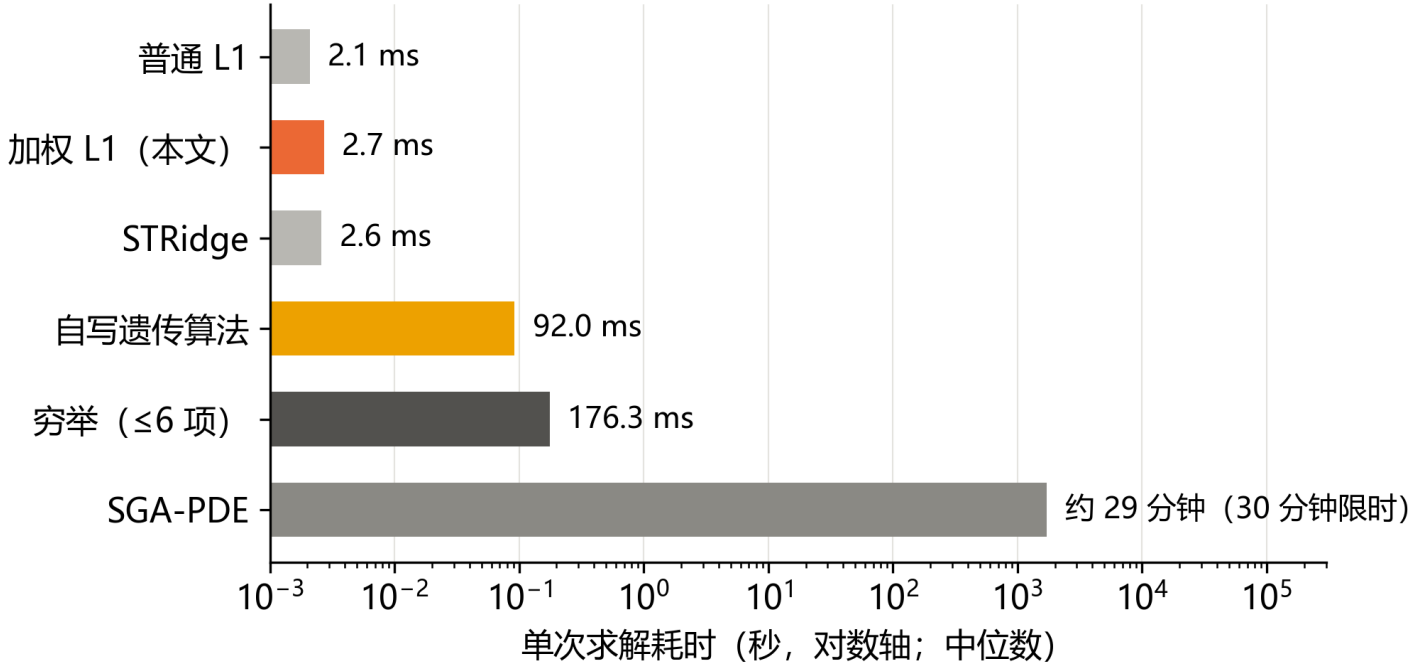
C–I = Chafee–Infante；compound：$u_t = (uu_x)_x$；divide*：$u_t = -u_x/x + 0.25u_{xx}$，需在库里加 4 个含 x 的项

噪声	SGA-PDE	加权 L1	说明
0%	3/7	7/7	SGA 两组 KdV、compound、divide 未找到
1%	**0/21**	**18/21**	我们错的 3 次都是 divide*（遗传算法和穷举对）
5%	**0/21**	**6/21**	我们失败的是小网格数据，穷举也错

公平性

SGA 论文报告这些方程都能找到，我们未复现：关了它的神经网络去噪；30 分钟内多数只跑到 24 ~ 94 代

计算代价：加权 L1 比遗传类方法快 1 ~ 6 个数量级



前五个方法：noise_inverse 全部实验的中位数；SGA-PDE：其数据集上 49 次运行的中位数，多数触到 30 分钟限时

为什么差这么多

- 加权 L1：LARS 一次给出整条路径，只评估约 15 个组合
- 遗传算法：每代 40 个个体 × 60 代，约 450 次评估
- 穷举：13 项里取 ≤ 6 项共 4096 种；库变大后组合数爆炸
- SGA-PDE：每个个体是一棵符号树，要重新求导、拟合，100 代

方法优劣总览

方法	需预设候选库	无噪声	抗噪声	计算量	结果确定	能发现库外项
普通 L1	需要	多留 u_x	差	极小	是	否
加权 L1（本文）	需要	全对	到 5%	极小（~15 次）	是	否
STRidge	需要	全对	1～3% 起掉	极小	是	否
自写遗传算法	需要	KdV 偶尔卡住	到 5%，7% 略好	中（~450 次）	否	否
穷举（判据上界）	需要	全对	到 5～7%	组合数爆炸	是	否
SGA-PDE	不需要	3/7	1% 起全错*	约 30 分钟	否	能

* 未开 SGA-PDE 的神经网络去噪、30 分钟限时；绿色 = 优势，橙色 = 一般，红色 = 劣势

建议：加权 L1 定支撑为主（快、确定、抗噪到 5%）；遗传算法作对照和兜底；库外项是固定库方法的共同局限。

结论、局限与下一步

结论

- L1 稀疏选择能同时求解析解和控制方程
- 加权 L1 修掉了普通 L1 多留 u_x 的问题
- 弱形式 + 统一判据后，反问题抗噪到 5%
- 比遗传类方法快 1 ~ 6 个数量级

局限

- 真项必须在候选库里（u_x/x 需另加）
- 正问题只覆盖单一行波
- 噪声门槛假定噪声大小已知
- 高噪声或库项相似时不如遗传算法

下一步

- 定正问题噪声门槛倍数（3 或 1.5）
- 论文加入噪声与遗传算法比较两节
- 设计多波候选库
- 确定作者、目标会议和页数